

StreamVault


JALON3 — Bilan Stratégique, sécurité et schéma final

Le dernier jalon ne demande plus de code il vérifie que vous comprenez ce que vous avez construit, au-delà de son bon fonctionnement technique.

Partie A — Manager l'innovation et sa dimension RSE (C2)

Q31 — Bilan des coûts réels

- Relevez vos coûts Azure réels sur la durée du brief (Coûts + Analyse des coûts du portail). Identifiez les 3 postes les plus élevés et expliquez pourquoi.



1. Identification du Top 3 des postes les plus élevés

La ventilation des coûts par service met en évidence les trois postes de dépenses prédominants :

1. Azure Event Hubs — 2,52 €

◦ *Explication technique* : C'est le poste le plus lourd du projet. Event Hubs est la brique d'ingestion de flux de données en temps réel. Dans le cadre de l'architecture (similaire à un système de streaming ou de traçage d'événements

e-commerce), ce service a été sollicité pour simuler ou collecter des flux continus. Le coût est principalement imputable à la réservation des unités de débit (*Throughput Units*) et au volume de messages ingérés/transités pendant les phases de tests.

2. Azure Data Factory v2 — 0,46 €

◦ *Explication technique* : Outil d'orchestration et d'intégration de données (ETL/ELT). Il a servi à automatiser le déplacement et la transformation des données entre les différentes sources. Le coût reflète le nombre d'exécutions de pipelines (*Pipeline Runs*) et les activités de brassage de données exécutées lors des phases de validation.

3. Azure Storage (Comptes de stockage) — 0,10 € (suivi de Logic Apps et Key Vault à < 0,01 €)

◦ *Explication technique* : Ce poste correspond au stockage persistant des fichiers bruts, des données de staging ou des journaux de logs. Le coût reste très modéré et dépend de la volumétrie stockée ainsi que du nombre d'opérations de lecture/écriture effectuées sur la période.

2. Analyse critique, dimension FinOps et RSE

- **Maîtrise budgétaire** : Avec un total de seulement 3,08 €, le dimensionnement global du projet démontre une excellente maîtrise des coûts, évitant le piège du surprovisionnement (*over-provisioning*) des environnements de test.
- **Impact RSE et sobriété numérique** : Du point de vue de la Responsabilité Sociétale des Entreprises, maintenir des flux de streaming (Event Hubs) ou des pipelines actifs uniquement lorsque cela est nécessaire permet de limiter l'empreinte énergétique des datacenters. L'optimisation des services managés évite le gaspillage de ressources de calcul et d'infrastructure superflues.

Q32 — Plus-value du streaming

En quoi le flux temps réel apporte-t-il un avantage stratégique concret pour StreamVault, au-delà de l'aspect technique ? Qu'est-ce que le batch seul ne permettrait pas ?

Pour **StreamVault** (qui gère un catalogue de médias, des clients, des commandes et des données géographiques), l'intégration d'un flux en temps

réel (via *Azure Event Hubs*) procure un avantage stratégique décisif qui va bien au-delà de la simple performance technique.

1. Les avantages stratégiques concrets du temps réel

- **Personnalisation et recommandation instantanée** : Le streaming permet d'analyser le comportement d'un utilisateur à la milliseconde (ex: un film ou un livre consulté, une commande passée). Cela permet d'ajuster immédiatement les recommandations de contenu ou de proposer des suggestions croisées (*cross-selling*) sur le vif, pendant que l'attention de l'utilisateur est maximale.
- **Réactivité commerciale et opérationnelle** : En capturant les commandes (**Commande**) et les données géographiques (**Commune**) au fil de l'eau, l'entreprise peut identifier instantanément des pics de popularité régionaux ou des tendances d'achat soudaines pour un type de média précis (*Film* vs *Livre*).
- **Expérience utilisateur fluide et engageante** : Offrir une plateforme qui réagit aux actions de l'utilisateur en direct renforce l'immersion et la fidélisation, des critères essentiels pour une plateforme de streaming et de e-commerce culturel.

2. Ce que le traitement par lot (*Batch*) seul ne permettrait pas

Le traitement *batch* (par exemple, un script qui s'exécute chaque nuit pour agréger les commandes de la veille) souffre d'un défaut structurel : **la latence temporelle**.

- **L'effet "temps perdu"** : En mode *batch*, si un contenu devient viral ou si une anomalie de commande survient à 14h, l'information n'est traitée qu'au prochain cycle d'exécution (souvent 24h plus tard). Il est alors trop réagir à chaud.
- **Impossibilité de déclencher des actions contextuelles** : Le batch ne permet pas de déclencher une action immédiate (comme une notification ciblée, un ajustement dynamique de mise en avant ou une alerte de stock/flux) au moment précis où l'événement se produit.
- **Perte de granularité comportementale** : Le batch lisse les données en agrégats globaux, faisant disparaître la chronologie fine des actions individuelles des clients.

En résumé, si le *batch* est indispensable pour le reporting financier global et l'analyse de fond (vision macro), le **streaming** apporte l'agilité nécessaire pour piloter l'activité en temps réel et maximiser l'engagement client (vision micro).

Q33 — Empreinte et sobriété

À partir de vos coûts observés, comparez l'impact d'un cluster laissé allumé en continu contre un arrêt automatique. Reliez votre analyse à l'ODD 9.

(article : <https://www.agenda-2030.fr/17-objectifs-de-developpement-durable/article/odd9-mettre-en-place-une-infrastructure-resiliente-promouvoir-une>)

À partir des coûts observés sur mon groupe de ressources Azure qui s'élèvent à **3,08 €**, voici l'analyse comparative entre un fonctionnement en continu et l'application d'un arrêt automatique, mise en perspective avec l'**ODD 9**.

1. Comparatif : Fonctionnement en continu vs Arrêt automatique

- **Fonctionnement en continu (24h/24) :**
 - *Impact financier* : Des services comme *Event Hubs* ou *Azure Data Factory* maintiennent des unités de calcul ou de débit réservées en permanence. Durant les phases creuses (nuits, week-ends, périodes sans tests), ces ressources génèrent des coûts superflus pour une utilité métier nulle.
 - *Impact énergétique* : Les serveurs du datacenter continuent de consommer de l'énergie électrique inutilement pour faire tourner des environnements inactifs.
- **Mise en place d'un arrêt automatique / Planification :**
 - *Impact financier* : En coupant ou en mettant en pause les services non essentiels en dehors des horaires de travail (par exemple, en passant d'un fonctionnement 24h/24 à une utilisation active de 8h par jour), il est possible de réduire significativement la facture (potentiellement de 60 % à 70 % sur les composants de calcul et de streaming).
 - *Impact énergétique* : Cette réduction du temps de fonctionnement se traduit directement par une baisse de la charge sur les serveurs

physiques et, par conséquent, une diminution de l'empreinte carbone globale du projet.

2. Lien avec l'ODD 9 (Industrie, innovation et infrastructure)

L'**Objectif de Développement Durable 9 (ODD 9)** de l'ONU vise à bâtir des infrastructures résilientes, promouvoir une industrialisation durable et encourager l'innovation.

- **L'innovation responsable** : Dans le domaine du cloud et de la data engineering, l'innovation ne se limite pas à concevoir des architectures performantes (comme le traitement en temps réel). Elle passe aussi par la capacité à optimiser et à concevoir des environnements sobres (*Green IT* et *FinOps*).
 - **Infrastructures durables** : Intégrer l'automatisation des arrêts et la gestion rigoureuse des ressources démontre une démarche d'ingénierie mature. Cela permet de répondre aux besoins de l'entreprise tout en minimisant l'impact environnemental des infrastructures technologiques, incarnant ainsi pleinement les valeurs de l'ODD 9.
-

Q34 — Feuille de route

Schématisez, avec un outil de conception de votre choix (Miro, Excalidraw, PowerPoint...), une feuille de route à 6-12 mois pour faire évoluer cette architecture chez StreamVault, incluant les impacts organisationnels (formation de l'équipe, nouveaux rôles nécessaires).

Phase 1 : Consolidation, FinOps et Sobriété (Mois 1 – 3)

- **Objectifs techniques** :
 - Automatiser l'arrêt des environnements de test et de développement hors des horaires de travail (réduction drastique des coûts et de l'empreinte carbone).
 - Stabiliser et documenter l'architecture de base (MongoDB, Azure Event Hubs, pipelines ADF).
- **Impacts organisationnels & Formation** :

- **Sensibilisation FinOps & Green IT** : Ateliers de formation pour l'équipe technique sur la gestion des coûts cloud et l'optimisation des ressources.
- **Nouveau rôle / Référent** : Désignation d'un référent *FinOps/Green IT* au sein de l'équipe de développement.

Phase 2 : Industrialisation du Streaming et Automatisation Sémantique (Mois 4 – 8)

- **Objectifs techniques :**
 - Déployer à grande échelle le script d'automatisation Python/RDFlib pour synchroniser dynamiquement la base MongoDB avec le modèle ontologique OWL.
 - Industrialiser les flux de streaming en temps réel pour alimenter les outils de Business Intelligence (Metabase / Power BI) avec des indicateurs de recommandation affinés.
- **Impacts organisationnels & Formation :**
 - **Montée en compétences ciblée** : Formation de l'équipe aux technologies de Web Sémantique (RDF, OWL, Protégé) et aux architectures de données orientées événements (*Event-Driven Architecture*).
 - **Nouveaux rôles** : Formalisation du rôle de **Data Engineer** (gestion des pipelines et du streaming) et intégration d'un profil ou d'une casquette **Semantic Data Architect**.

Phase 3 : Gouvernance, IA et Évolutivité (Mois 9 – 12)

- **Objectifs techniques :**
 - Mettre en place une gouvernance stricte des données (Data Catalog) et renforcer la sécurité des accès.
 - Intégrer des modèles prédictifs ou d'intelligence artificielle (ex: Azure OpenAI / modèles de recommandation avancés) connectés au graphe de connaissances.
- **Impacts organisationnels & Formation :**

- **Gouvernance et conformité** : Formations sur la sécurité des données et le respect de la vie privée (RGPD).
 - **Nouveau rôle** : Création ou formalisation du rôle de **Data Governance Officer** pour superviser la qualité et l'éthique de la donnée.
-

Partie B — Analyser le SI construit (C4)

Q35 — Document de Conception Technique

Rédigez un DCT de 2-3 pages décrivant votre architecture : composants, flux de données, choix techniques justifiés, contraintes rencontrées. Structurez-le clairement (sommaire, sections dédiées par composant).

Sommaire

1. Introduction et Contexte du Projet
2. Architecture Globale et Composants
3. Flux de Données
4. Choix Techniques Justifiés
5. Contraintes, Gouvernance et Dimension FinOps / RSE

1. Introduction et Contexte du Projet

StreamVault est une plateforme moderne de gestion et d'analyse de données culturelles et e-commerce (regroupant des catalogues de médias de type *Films* et *Livres*, des profils de *Clients*, des *Commandes* ainsi que des données géographiques de *Communes*).

L'objectif de ce document est de présenter l'architecture technique mise en œuvre pour répondre à un double défi :

- Assurer une ingestion et un traitement performant des données (alliant traitement par lots, flux hybrides et streaming temps réel).
- Structurer la connaissance métier à travers une ontologie sémantique (RDF/OWL) tout en garantissant une exploitation décisionnelle (Business

Intelligence) sobre et optimisée sur le plan financier et environnemental (*FinOps* et *Green IT*).

2. Architecture Globale et Composants

L'architecture repose sur un écosystème hybride combinant des briques NoSQL locales, une infrastructure virtualisée locale (KVM), des services managés cloud sur **Microsoft Azure** (au sein du groupe de ressources **gelbajouryRG**) [cite: 10] et une couche de visualisation conteneurisée.

A. La couche Source, Stockage NoSQL et Virtualisation Locale

- **MongoDB** : Base de données orientée documents, idéale pour stocker des structures de données semi-structurées et évolutives (collections de catalogues mixtes, clients, commandes).
- **VM Windows sur KVM (Hyperviseur local)** : Machine virtuelle Windows hébergée localement servant de passerelle d'intégration (*Self-Hosted Integration Runtime - SHIR*), permettant de lier l'environnement local aux services cloud de manière sécurisée.

B. La couche Cloud Azure (**gelbajouryRG**)

- **Azure Event Hubs** : Brique d'ingestion de flux de données en temps réel (streaming haut débit).
- **Azure Data Factory v2 (ADF)** : Outil d'orchestration et d'intégration de données (ETL/ELT) pour automatiser les pipelines de transfert et de transformation.
- **Azure Storage** : Stockage persistant pour les données brutes, les fichiers de staging et les journaux de traçage.
- **Services complémentaires** : Azure Logic Apps et Key Vault pour l'automatisation des flux et la sécurisation des secrets.

C. La couche Sémantique et Décisionnelle

- **WebVOWL / Protégé** : Outils de modélisation et de visualisation de l'ontologie RDF/OWL.
- **Metabase** : Outil de Business Intelligence et de datavisualisation déployé via Docker (conteneurisé avec un mapping de port **3000:3000**) pour restituer les indicateurs métiers.

3. Flux de Données

Le système gère trois types de flux complémentaires :

- **Le Flux Temps Réel (Streaming)** : Les événements de commandes et d'interactions utilisateurs capturés sur la plateforme sont émis en continu vers **Azure Event Hubs**. Ce flux permet de réagir à chaud (recommandations instantanées, alertes de popularité) sans attendre les traitements nocturnes.
- **Le Flux Hybride & Orchestration (Sécurisé par la passerelle SHIR) : Azure Data Factory v2** orchestre les extractions de données. Ne pouvant accéder directement au réseau local pour des raisons de sécurité, ADF délaye l'exécution à l'agent *Self-Hosted Integration Runtime* hébergé sur la **VM Windows sous KVM**. Cette dernière récupère les données de **MongoDB** localement et les transmet de manière sécurisée vers les pipelines Azure pour alimenter les tables de staging et de restitution.
- **Le Flux Sémantique et Décisionnel** : La structure des données extraites est mappée à l'ontologie OWL pour relier les concepts (*Media, Film, Livre, Client, Commande, Commune*). **Metabase** se connecte aux entrepôts de données pour permettre aux équipes métiers de requêter et visualiser les KPI de performance.

4. Choix Techniques Justifiés

- **Choix de MongoDB (NoSQL) vs SGBDR relationnelle** : La flexibilité du NoSQL a été privilégiée pour absorber la variabilité des attributs des médias (les propriétés d'un *Film* comme la note IMDb différent de celles d'un *Livre* comme le nombre de pages).
- **Mise en place d'une architecture hybride via Self-Hosted IR (VM Windows sur KVM)** : L'utilisation d'une machine virtuelle locale comme passerelle d'intégration évite d'exposer la base MongoDB directement sur le web public. Cela garantit une cloison étanche et sécurisée entre l'infrastructure on-premise et l'orchestrateur cloud Azure Data Factory.
- **Choix du Streaming (Event Hubs) couplé au Batch** : Le traitement par lot seul (*Batch*) génère une latence incompatible avec l'expérience utilisateur moderne. L'association Event Hubs + ADF permet de conjuguer la réactivité immédiate (micro) et la consolidation analytique globale (macro).

- **Modélisation par Ontologie RDF/OWL** : L'utilisation du Web sémantique permet d'interroger les données non pas par de simples jointures SQL rigides, mais par le biais de relations logiques et inférentielles, facilitant l'interopérabilité des données de StreamVault.

5. Contraintes, Gouvernance et Dimension FinOps / RSE

A. Bilan des Coûts et Analyse FinOps

Le suivi des coûts réalisé sur le groupe de ressources Azure `gelbajouryRG` indique un montant total maîtrisé de **3,08 €**, ventilé comme suit :

- **Azure Event Hubs** : 2,52 € (poste principal lié à la réservation des unités de débit et à l'ingestion des flux)[cite: 10].
- **Azure Data Factory v2** : 0,46 € (lié aux exécutions de pipelines)[cite: 10].
- **Azure Storage** : 0,10 € (stockage persistant des données)[cite: 10].

B. Contraintes Techniques Résolues

- **Accès Metabase** : Résolution d'un problème de routage réseau par le re-paramétrage du conteneur Docker avec un mapping explicite du port `3000:3000`.
- **Connectivité Hybride Cloud-Local** : Contournement du blocage de sécurité réseau entre le cloud Azure et l'infrastructure locale par le déploiement et la configuration de l'agent d'intégration sur la VM Windows hébergée sur l'hyperviseur KVM.

C. Sobriété Numérique et Alignement RSE (ODD 9)

Dans une optique d'infrastructure durable (en lien avec l'**ODD 9 — Industrie, innovation et infrastructure**), la maîtrise des coûts cloud se traduit directement par une réduction de l'empreinte carbone. La mise en place future d'arrêts programmés des services de streaming et de calcul hors des heures de travail permettra d'éviter le gaspillage énergétique dans les datacenters tout en optimisant l'efficacité financière du projet.

Partie C — Sécuriser un pipeline temps réel (C28)

Q38 — Test de continuité

Provoquez une coupure volontaire du flux streaming en pleine exécution (arrêtez le consommateur, ou le producteur, en plein envoi). Redémarrez-le. Vérifiez et documentez : une commande a-t-elle été perdue ?

Q38 (Test de continuité du Streaming)

1. Protocole du test réalisé

- **Action 1** : Lancement du script producteur (`producteur.py`) pour envoyer des flux de commandes en continu vers **Azure Event Hubs**.
- **Action 2** : Interruption volontaire du script en plein milieu de l'exécution (via un `Ctrl+C` ou arrêt forcé du processus).
- **Action 3** : Attente de quelques secondes, puis redémarrage du producteur.

2. Constat / Observation

- Pendant la coupure, l'émission des événements est momentanément suspendue.
- Dès le redémarrage, le script se reconnecte instantanément à l'Event Hub et reprend l'envoi des commandes sans erreur critique ni corruption de données.
- **Résultat** : Aucun message émis avant la coupure n'a disparu, et le système reprend son fonctionnement nominal de manière fluide.

3. Justification technique (Pourquoi aucune donnée n'est perdue ?)

Ce comportement réside dans l'architecture robuste d'**Azure Event Hubs** :

- **Persistance côté Cloud** : Les messages envoyés par le producteur sont immédiatement stockés et tamponnés dans le stockage interne de l'Event Hub (selon la politique de rétention configurée). Ils n'attendent pas qu'un consommateur soit connecté en temps réel pour être conservés.
- **Gestion des offsets et des checkpoints (Côté consommateur)** : Si le consommateur venait à s'arrêter en même temps, il utilise un système de *checkpoints* (points de contrôle) ou d'indexation (*offsets*). Au redémarrage, il sait exactement quel message il a traité en dernier et reprend sa lecture

exactement là où il s'était arrêté, garantissant une politique de livraison fiable (*at-least-once delivery*).

Q39 — Documenter la sécurisation

Récapitulez, dans un court document, les mesures de sécurité déjà en place dans votre pipeline (secrets, contrôle d'accès, chiffrement en transit) — même si elles n'ont jamais été formalisées jusqu'ici.

Mesures de sécurité et de gouvernance mises en œuvre au sein de l'architecture technique de StreamVault, couvrant la gestion des secrets, le contrôle des accès et la protection des flux en transit.

1. Gestion des Secrets (Secrets Management)

Afin de bannir toute inscription en dur (*hardcoding*) de mots de passe ou de clés sensibles dans le code source ou les notebooks, la gestion des secrets est externalisée et sécurisée :

- **Azure Databricks Secrets Scopes** : Les informations sensibles (comme le nom du compte de stockage et la clé d'accès principale) sont récupérées dynamiquement à l'exécutable via l'API sécurisée `dbutils.secrets.get()` rattachée à un scope dédié (`groot-storage-scope`).
- **Azure Key Vault** : Utilisation des services de coffre-fort dans Azure pour stocker les chaînes de connexion, certificats et tokens d'accès aux différentes briques (Event Hubs, stockage, bases de données).

2. Contrôle d'Accès et Gestion des Identités (IAM)

L'accès aux ressources du Cloud Azure et de l'infrastructure locale est strictement cloisonné :

- **Contrôle d'accès basé sur les rôles (RBAC)** : Les services Azure communiquent via des principes de moindre privilège, limitant les droits d'écriture et de lecture stricts aux seuls composants autorisés (par exemple, les pipelines ADF accédant aux conteneurs `raw` et `clean`).
- **Cloisonnement de la base de données locale** : L'instance **MongoDB** hébergée sur la machine virtuelle locale n'est pas exposée directement sur Internet ; elle est protégée par un accès authentifié et restreint aux scripts internes (`producteur.py`) et au runtime d'intégration.

3. Chiffrement en Transit et Sécurité Réseau (Networking)

La protection des données en mouvement repose sur des protocoles robustes et une architecture hybride étanche :

- **Chiffrement en transit (TLS / HTTPS)** : Tous les échanges entre les services managés Azure (Event Hubs, Storage Accounts, Data Factory, Databricks) et les scripts clients s'effectuent via des canaux chiffrés en HTTPS/TLS.
 - **Passerelle d'intégration sécurisée (SHIR)** : Pour connecter de manière sécurisée le Cloud Azure à l'infrastructure locale (MongoDB), l'utilisation du *Self-Hosted Integration Runtime* (SHIR) évite d'ouvrir des ports publics entrants, garantissant un tunnel d'intégration contrôlé et chiffré entre le Cloud et l'environnement local virtualisé (KVM).
-

Q40 — Point de vulnérabilité

Identifiez le point le plus critique de votre architecture en cas de compromission (quel service, quelle donnée), et proposez une mesure de mitigation réaliste.

1. Identification du point le plus critique

Le point le plus critique de l'architecture est **la machine virtuelle locale hébergeant simultanément la passerelle SHIR (*Self-Hosted Integration Runtime*) et la base de données MongoDB**.

- **Pourquoi ?** C'est le pivot (*choke point*) central de ton architecture hybride. C'est elle qui fait la jonction entre le Cloud Azure et l'infrastructure locale.
- **En cas de compromission** : Un attaquant qui parvient à s'introduire sur cette machine locale obtiendrait un accès direct à la base de données **MongoDB** (contenant les données sensibles des clients, les catalogues et les commandes) et pourrait potentiellement détourner le canal d'intégration sécurisé du SHIR pour perturber les pipelines de données en provenance d'Azure.

2. Mesure de mitigation réaliste

Pour réduire drastiquement ce risque sans alourdir inutilement l'architecture, plusieurs mesures concrètes et réalistes peuvent être appliquées :

- **Cloisonnement et durcissement réseau (*Network Hardening*)** :

- S'assurer que le service MongoDB sur la machine locale n'écoute que sur l'interface de bouclage interne (`localhost`) ou un réseau local privé virtuel, et qu'aucun port de base de données n'est ouvert ou exposé sur le Web public.
 - Restreindre les flux entrants de la passerelle SHIR aux seules adresses IP et services managés stricts d'Azure Data Factory.
 - **Mise en place d'une authentification stricte et rotation des secrets :**
 - Activer l'authentification renforcée sur MongoDB (avec des rôles RBAC aux privilèges stricts plutôt qu'un accès root global).
 - Proscrire l'écriture en dur des chaînes de connexion dans les fichiers de configuration locaux en privilégiant l'utilisation de coffres sécurisés (comme **Azure Key Vault** ou les scopes chiffrés Databricks).
 - **Principe du moindre privilège :**
 - Isoler le service exécutant le SHIR avec un compte utilisateur dédié disposant uniquement des droits minimaux nécessaires à l'exercice de sa tâche d'intégration.
-

Partie D — Schéma final de votre propre architecture

Q41 — Dessiner votre architecture réelle

Sans copier un schéma déjà vu dans le cours, dessinez (au format de votre choix, un diagramme Mermaid est recommandé) l'architecture complète de VOTRE pipeline tel que vous l'avez réellement construit : tous les services Azure utilisés, tous les flux de données, la distinction claire entre batch et streaming. Si votre implémentation diffère de ce qui était demandé, votre schéma doit refléter la réalité, pas la consigne.